

中国矿业大学
计算机科学与技术学院

2023 级本科生课程设计期末报告

课程名称 人工智能综合实践

设计题目 PPO 深度强化学习的峡谷寻宝智能体设计与优化

开课学期 2025-2026 学年第 2 学期

报告时间 2026. 08. 28

学生姓名 刘润章、陈旭东、南怡波

学 号 08231920、08231500、08234033

班 级 人工智能 2 班

专 业 人工智能

任课教师 杜文亮

《人工智能综合实践》课程报告评分表

开课学期：2025-2026 学年第 2 学期

姓名：刘润章、南怡波、陈旭东

专业班级：人工智能 2 班

序号	毕业要求	课程教学目标	考查方式与考查点	占比	得分
1	3.4	目标 2： 在人工智能算法设计过程中，能够对基本的算法进行合理的分析和运用；针对具体实际问题，正确实现数据的表达、计算和存储。	实验代码及报告、综合实验。 重点考查学生分析和运用基本算法的合理性，以及运行结果的正确性。	50%	
2	10.3	目标 3： 能够在开发平台上编制人工智能算法，实现具体问题的解决方案，并能够对数据和运行结果进行合理的解释和分析。	实验代码及报告、综合实验。 重点考查学生对问题解决方案及运行结果的分析和改进能力。	50%	
总成绩				100%	

任课教师：杜文亮

2026 年 8 月 28 日

初赛 37/158 打榜分数：997.15，未进决赛。最终获区域三等奖

模型列表 测评任务 测评成绩

选择团队

排名	团队名称	完成局数(总局数)	平均得分
31	巨大历史机遇	150 (150)	1031.51
32	DDL是第一生产力	150 (150)	1025.48
33	求地得排队	150 (150)	1015.90
34	自爆小组	150 (150)	1014.08
35	码头有大码头来了	150 (150)	1007.36
36	赛博农p	150 (150)	1006.99
37	ChatGPT	150 (150)	997.15
38	RL领域top1	150 (150)	995.38
39	狼队Star超会玩	150 (150)	992.64
40	做的都对	150 (150)	978.49

< 1 2 3 4 5 6 ... 16 >



第十七届中国大学生服务外包创新创业大赛
东部区域赛
南京·鼓楼

人工智能专项赛道 三等奖

参赛院校
中国矿业大学

参赛学生
刘润章 中国矿业大学
陈旭东 中国矿业大学
南怡波 中国矿业大学

指导老师
杜文亮 中国矿业大学
姚 睿 中国矿业大学



中国大学生服务外包创新创业大赛东部区域赛组委会
二〇二六年六月

基于 PPO 深度强化学习的峡谷寻宝智能体设计与优化

《人工智能综合实践》课程设计报告

项目方向：深度强化学习 / 智能体决策

最终训练包：gorge_chase-ppo-34055-2026_04_27_09_07_26-15.0.1

摘要

本课程设计以峡谷追猎类智能体竞赛任务为背景，研究在存在动态怪物、宝箱、加速BUFF、障碍物与技能冷却约束的离散环境中，如何利用深度强化学习实现鲁班七号智能体的自主寻宝与生存决策。针对基础策略容易出现只顾生存、不主动寻宝、在局部区域反复徘徊、进入死胡同以及闪现技能使用时机不合理等问题，设计了一套基于近端策略优化（Proximal Policy Optimization, PPO）的改进方案。最终方案将英雄、怪物、宝箱、BUFF、地形拓扑和历史记忆等结构化信息与8通道21×21局部地图共同作为状态输入；利用多分支MLP和CNN分别完成特征编码，并通过动态门控机制对不同类型的上下文特征进行自适应融合。在特征工程层面，引入局部BFS可达距离、宝箱与BUFF位置缓存、方向可达区域分析和近期行为记忆；在奖励函数层面，将宝箱收益、生存安全、怪物夹击、死胡同、开阔度、BUFF获取、闪现质量以及防磨蹭等因素综合进行奖励塑形。训练阶段采用地图1~8顺序训练，并在训练流程中独立使用地图9、10进行周期性轻量验证，以降低仅记忆训练地图造成的过拟合风险。最终训练包保存了编号为34055的模型检查点。本设计展示了将深度强化学习、局部路径规划和显式记忆相结合解决复杂动态决策问题的完整工程过程。

关键词：深度强化学习；PPO；Actor-Critic；奖励塑形；BFS；智能体决策

目 录

- 1 绪论 7
- 2 任务与环境分析 8
- 3 PPO 算法原理与训练方法 9
- 4 智能体模型结构设计 11
- 5 特征工程与局部规划改进 12
- 6 奖励函数设计与策略优化 13
- 7 训练流程与工程实现 14
- 8 实验结果与分析 16
- 9 关键代码分析 17
- 10 总结与展望 18
- 参考文献 19
- 附录 A 最终工程文件说明 19

1 绪论

1.1 项目背景

强化学习通过智能体与环境持续交互，使智能体依据状态选择动作，并根据环境反馈的奖励信号不断优化策略。与传统监督学习相比，强化学习不要求为每一个状态提供人工标注的最优动作，更适合处理连续决策、长期收益和动态环境下的自主控制问题。峡谷寻宝任务同时包含探索、避障、资源收集、生存和技能管理等目标，是检验强化学习智能决策能力的典型综合场景。

本项目来源于实际竞赛任务。智能体控制鲁班七号在峡谷地图中移动，一方面需要尽可能收集宝箱并利用加速 BUFF 提高行动效率，另一方面需要持续避开动态怪物并避免被夹击。随着对局推进，怪物数量和移动速度会改变，智能体还需要判断何时使用带冷却时间的闪现技能。上述因素使任务具有部分可观测、目标冲突和长时序信用分配等特点。

1.2 主要问题与设计目标

在前期训练过程中，单纯依赖稀疏的终局或宝箱奖励容易造成策略收敛缓慢；若过度强调与怪物保持距离，又可能形成“只求活着、不主动找箱子”的保守策略；局部地图中的障碍物还会导致智能体在墙角、狭窄通道或死胡同中反复摩擦。此外，宝箱和 BUFF 并非始终处于当前视野内，仅依据当前帧信息会造成目标丢失。

因此，本课程设计的目标是构建一套能够兼顾生存与寻宝的 PPO 智能体，并从状态表示、模型结构、奖励塑形、局部路径信息、目标记忆和训练验证流程等方面进行工程化改进。重点解决以下问题：①如何将不同类型的信息组织成稳定的状态表示；②如何让模型从局部地图中提取空间特征；③如何设计奖励，使策略既避险又主动推进目标；④如何缓解原地徘徊、撞墙和闪现滥用；⑤如何通过独立验证地图观察泛化趋势。

1.3 本文主要工作

本文主要完成以下工作：构建 3601 维统一观测表示；设计多分支特征编码与 CNN 地图编码相结合的 Actor-Critic 网络；采用 PPO 剪切目标完成策略优化；引入 GAE 计算优势函数；利用 BFS、拓扑特征和位置缓存增强局部规划能力；设计多因素奖励函数；将训练地图与验证地图分离，并保存最终模型检查点用于部署与后续评估。

2 任务与环境分析

2.1 任务描述

任务场景由英雄、障碍物、宝箱、BUFF 和动态怪物组成。智能体每一步根据环境观测选择一个离散动作，环境返回新的观测、得分、终止状态和合法动作信息。对局的直接目标是提高综合得分，其行为层面的核心要求可以概括为“在尽可能长时间存活的同时，高效收集宝箱并合理利用 BUFF 与闪现”。

2.2 最终训练环境配置

配置项	最终值	说明
训练地图	1~8	按顺序抽取，map_random=false
验证地图	9、10	不参与训练，仅用于周期性轻量验证
宝箱数量	10	每局配置 10 个宝箱
BUFF 数量	2	每局配置 2 个加速 BUFF
BUFF 刷新冷却	200 步	拾取后经过 200 步重新生成
闪现技能冷却	200 步	技能施放后进入冷却
第二怪物出现间隔	200 步	用于增加中后期生存压力
怪物加速时间	300 步	开局 300 步后怪物移动能力增强
最大单局步数	1000 步	达到上限后对局截断结束

表 2-1 最终训练环境主要配置

2.3 状态空间设计

最终版本将观测拆分为 6 类结构化特征和 1 类局部地图特征。结构化特征总计 73 维，局部地图为 $8 \times 21 \times 21 = 3528$ 维，展平后总观测维度为 3601。与直接将所有原始数据无差别拼接相比，这种分组方式便于分别建模英雄自身状态、敌方威胁、目标资源和历史信息。

特征分支	维度	主要含义
英雄特征	14	英雄位置、步数/宝箱得分、已收集数量、闪现可用性与冷却、移动速度等
怪物特征	16	怪物相对位置、距离、BFS 路径距离、最近怪物距离、危险度、夹击程度等
宝箱特征	14	可见宝箱比例、缓存比例、最优可见目标、缓存目标及 BFS 距离等
BUFF 特征	8	BUFF 状态、最近目标距离、缓存目标、BUFF 计时与闪现相关统计
拓扑特征	13	开阔度、障碍密度、分支数、死胡同风险、贴墙程度及方向 BFS 质量
记忆特征	8	近期位置、访问多样性、进度、重复访问和防磨蹭标志等
局部地图	3528	8 通道 $\times 21 \times 21$ ，包含可行走区域、障碍、英雄、怪物、宝箱、BUFF、访问痕迹和危险度

表 2-2 最终状态空间组成

2.4 动作空间与合法动作约束

最终动作空间大小为 16。工程中通过 `legal_action` 向量对不可执行动作进行掩码，训练时在 Softmax 之前将非法动作对应的 logit 减去极大值，推理时同样仅在合法动作上归一化和采样。这样能够避免策略把概率质量浪费在当前不可执行的动作上，并提高训练稳定性。根据竞赛动作定义，16 个动作可理解为 8 个方向的普通移动与对应方向的技能/闪现类动作。

3 PPO 算法原理与训练方法

3.1 Actor-Critic 框架

本项目采用 Actor-Critic 框架。Actor 根据状态 s 输出 16 个动作的策略分布 $\pi(a|s)$ ，Critic 输出状态价值 $V(s)$ 。Actor 负责选择行为，Critic 负责估计当前状态的长期收益，为策略更新提供低方差的学习信号。

3.2 PPO 剪切目标

PPO 通过限制新策略与旧策略之间的更新幅度，避免一次梯度更新使策略发生过大变化。代码中保存采样时旧策略对全部动作的概率，并在训练时取出实际动作对应的旧概率，与新策略概率计算重要性采样比率。

$$r_t(\theta) = \pi_{\theta}(a_t|s_t) / \pi_{\{\theta_{old}\}}(a_t|s_t)$$

$$L_{clip}(\theta) = E_t[\min(r_t(\theta)A_t, \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon)A_t)]$$

最终配置中剪切参数 $\epsilon=0.2$ 。工程实现对策略损失取负号进行梯度下降，并统计 `clip_frac`、`approx_kl`、`ratio_mean` 和 `ratio_std` 等指标，以便监控每次策略更新的幅度。

3.3 GAE 优势估计

为兼顾偏差和方差，样本处理阶段采用广义优势估计（GAE）。最终配置 $\gamma=0.99$ ， $\lambda=0.95$ 。对于每一步，先计算时序差分误差，再从轨迹末端向前递推优势函数。

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

$$A_t = \delta_t + \gamma \lambda (1 - d_t) A_{t+1}$$

代码中进一步令 `reward_sum=A_t+V(s_t)` 作为价值网络回归目标，并默认对一个训练批次中的优势进行标准化，减少不同轨迹奖励尺度变化对策略更新的影响。

3.4 价值函数、熵与总损失

价值网络默认启用 value clip，与 PPO 策略剪切类似，限制新旧价值估计之间的突变。总损失由价值损失、策略损失和策略熵共同组成。熵项用于维持一定探索性，防止策略过早退化为确定性动作。

$$L = 0.5 L_{\text{value}} + L_{\text{policy}} - 0.005 H(\pi)$$

训练使用 Adam 优化器，初始学习率为 3×10^{-4} ，梯度范数裁剪阈值为 0.5。每批样本执行 4 轮 PPO 更新，mini-batch 大小为 256。

超参数	取值
折扣因子 γ	0.99
GAE 参数 λ	0.95
初始学习率	3×10^{-4}
熵系数	0.005
PPO Clip	0.2
价值损失系数	0.5
梯度裁剪	0.5
PPO Epochs	4
Mini-batch	256
优势标准化	开启
价值剪切	开启

表 3-1 PPO 主要超参数

4 智能体模型结构设计

4.1 多分支编码结构

不同类别特征的统计性质差异较大。例如英雄状态主要是低维连续量，局部地图则具有明显二维空间结构。因此最终模型没有直接使用单一全连接网络处理 3601 维输入，而是采用多分支编码：6 类结构化特征分别经过两层 MLP，每个分支编码为 32 维；8 通道局部地图则经过 3 层卷积、最大池化和自适应平均池化，最后映射为 64 维地图嵌入。




图 4-1 最终 PPO 智能体网络结构

4.2 动态门控上下文融合

为了避免怪物、宝箱、BUFF、拓扑和记忆信息在所有状态下被同等对待，模型以英雄嵌入和地图嵌入作为门控输入，通过两层全连接网络输出 5 个权重，并经过 Softmax 归一化。随后对怪物、宝箱、BUFF、拓扑和记忆 5 个 32 维分支进行加权求和，得到上下文向量。

$$g = \text{softmax}(f_gate([e_hero, e_map]))$$

$$e_context = \sum_i g_i e_i, \quad i \in \{\text{monster, treasure, buff, topo, memory}\}$$

这种结构可以使网络在危险状态下更关注怪物和拓扑信息，在相对安全时更多利用宝箱、BUFF 和记忆信息。最终将英雄嵌入、地图嵌入和门控上下文拼接后，经 128 维融合网络产生 Actor 与 Critic 两个输出头。

4.3 局部地图 8 通道表示

局部地图大小为 21×21 ，8 个通道分别描述可行走区域、障碍区域、英雄当前位置、怪物位置、宝箱位置、BUFF 位置、近期访问痕迹以及基于怪物距离构造的局部危险度。与只输入目标相对坐标相比，CNN 能够同时观察障碍结构和目标空间分布，有利于学习“绕开障碍”“避免进入封闭区域”等空间行为。

5 特征工程与局部规划改进

5.1 BFS 可达距离

欧氏距离只能反映几何上的直线远近，无法区分“看起来很近但被墙隔开”的目标。最终版本在 21×21 局部可行走网格上计算 BFS 距离，用于估计怪物、宝箱和 BUFF 的实际局部路径距离，并构造 8 个方向的可达质量特征。由于局部地图规模固定，BFS 计算开销可控，却能够显著补充纯神经网络对地图连通性的感知。

5.2 宝箱与 BUFF 位置缓存

宝箱和 BUFF 可能暂时离开当前视野。预处理器维护宝箱记忆矩阵和 BUFF 记忆矩阵：当目标被看到时记录对应位置；宝箱记忆随时间按 0.995 衰减，并在确定宝箱已被拾取后清理附近记忆；BUFF 点位由于会刷新，因此看到后长期保留。缓存目标与当前可见目标共同进入特征向量，使智能体具备简单的长期目标记忆能力。

5.3 拓扑风险与方向特征

预处理器从局部地图中计算开阔度、障碍密度、分支数量、死胡同风险和贴墙程度，并补充按方向统计的 BFS 质量。这样，模型不仅知道“最近怪物在哪里”，还可以判断某个方向是否具有更大的逃生空间。在双怪夹击或怪物加速阶段，此类地形信息尤其重要。

5.4 防磨蹭记忆

前期策略容易在障碍边缘或局部区域来回摩擦。最终版本维护近期位置队列，并回看 10 步前的位置。如果当前点与 10 步前点的 L2 距离小于 5，则认为可能发生小范围磨蹭。该标志作为记忆特征输入模型，同时在安全、未获得宝箱和 BUFF 的条件下触发轻量负奖励，从而鼓励智能体离开无收益循环。

6 奖励函数设计与策略优化

6.1 奖励设计原则

奖励函数需要同时解决“活下来”和“主动完成任务”两个目标。若只奖励宝箱，早期随机策略很难频繁获得正反馈；若只奖励生存距离，智能体又可能学成单纯绕圈。因此最终版本采用分层奖励塑形：主奖励反映步数收益和宝箱收益，辅助奖励描述生存、地形、BUFF、目标推进和动

作质量，并对终局结果进行额外修正。

奖励项	最终系数/值	作用
步数收益	$0.02 \times \text{step_gain}$	提供基础生存反馈
宝箱收益	$1.2 \times \text{treasure_gain} / 100$	强化主要任务目标
拾取 BUFF	+0.35	鼓励合理利用加速资源
安全距离变化	$0.10 \times \Delta \text{dist}$	鼓励与怪物拉开距离
危险度变化	$0.12 \times \Delta \text{danger}$	降低综合危险状态
夹击变化	$0.08 \times \Delta \text{squeeze}$	减轻双怪压缩
死胡同风险	$-0.05 \times \text{risk} \times \text{pressure}$	避免进入不利地形
开阔度	$+0.03 \times \text{open} \times \text{pressure}$	危险时偏向更开阔区域
接近宝箱	$0.015 \times \Delta \text{distance}$	仅在相对安全时启用
接近 BUFF	$0.012 \times \Delta \text{distance}$	满足条件时作为辅助目标
无效移动	-0.03	惩罚撞墙或几乎无位移
防磨蹭	-0.10	安全且无收益时惩罚局部循环
终止失败	-2.0	强化生存约束
达到最大步数	+1.2	奖励完整存活
异常截断	-0.5	区分正常完成与异常结束

表 6-1 奖励塑形主要组成

6.2 条件化目标推进奖励

接近宝箱并非任何时候都给予奖励。代码要求当前危险度低于 0.35 且本步没有直接获得宝箱时，才根据与最佳宝箱目标的距离变化计算接近奖励。这一条件化设计可以避免智能体在怪物已经逼近时仍为了短期宝箱收益强行冲向目标。BUFF 接近奖励的条件更严格：当前未处于 BUFF 状态、没有刚拾取 BUFF 或宝箱、危险度低于 0.55、BUFF 距离不超过 18，并且附近没有更直接的宝箱目标。

6.3 动态生存压力

当对局步数进入后期或当前危险度较高时，生存相关奖励乘以 1.3 的压力系数。这样可以策略在怪物加速或紧急状态下提高对距离、危险度和夹击变化的敏感程度，而在安全阶段保留更多探索和寻宝空间。

6.4 闪现技能质量评价

最终版本没有简单地“使用闪现就奖励”，而是比较闪现前后的怪物距离、BFS 路径距离、危险度和开阔度。高危状态下若闪现能够明显拉开距离或降低危险，则给予+0.20；高危却未形成有效脱险则给予-0.12。中危状态下要求同时获得一定逃生收益和更开阔地形才给+0.08，否则为-0.04；低危情况下无意义闪现为-0.05，而安全地利用闪现完成宝箱收益可获得+0.04。该设计直接约束技能使用质量，有助于减少冷却资源浪费。

7 训练流程与工程实现

7.1 训练与验证分离

训练环境由 `train_env_conf.toml` 固定使用地图 1~8，并设置 `map_random=false` 按顺序轮换。训练 workflow 额外构造验证配置，使用地图 9、10 进行轻量验证。验证 episode 不发送样本、不参与梯度更新，只统计 `val_reward`、`val_total_score`、`val_steps`、`val_treasures` 和 `val_terminated_rate` 等指标。该设计从流程上把“训练表现”和“未见地图泛化趋势”分开。




图 7-1 最终训练与验证流程

7.2 样本组织与 PPO 更新

每一步样本包括 3601 维观测、16 维合法动作、实际动作、奖励、done 标志、旧策略概率、状态价值、下一状态价值、优势和回报等固定长度数组。一个 episode 结束后再统一通过 GAE 计算 advantage 和 `reward_sum`，然后发送给训练算法。训练算法随机打乱批次并切分 mini-batch，执行 4 轮 PPO 更新。

7.3 监控指标

训练代码每隔约 60 秒上报一次优化指标，包括 `cum_reward`、`total_loss`、`value_loss`、`policy_loss`、`entropy_loss`、`grad_clip_norm`、`clip_frac`、`explained_var`、`approx_kl`、`ratio_mean`、`ratio_std`、`adv_mean`、`adv_std` 和 `ret_mean`。验证阶段则上报独立的 `val_*` 指标。这些指标为排查“策略更新过大”“价值网络拟合不足”“探索性过低”等问题提供了依据。

8 实验结果与分析

8.1 方案改进分析

从最终版本的代码结构可以看出，方案针对早期强化学习训练中的典型失败模式进行了有针对性的改进。第一，BFS 距离解决了欧氏距离无法反映墙体阻隔的问题；第二，宝箱和 BUFF 缓存缓解了目标离开视野后的信息丢失；第三，拓扑与开阔度特征使模型能够显式感知死胡同和逃生空间；第四，防磨蹭机制直接针对局部重复移动；第五，闪现奖励由“是否使用”升级为“是否产生有效脱险或任务收益”；第六，训练图与验证图分离，避免只观察训练地图收益导致对泛化能力的误判。

这些改进体现了本项目并非简单调用 PPO 算法，而是围绕具体竞赛环境对状态表达、网络结构、奖励函数和训练流程进行了联合设计。特别是“神经网络学习策略 + BFS 提供局部可达信息 + 显式记忆保留目标线索”的组合，使端到端学习和传统搜索方法各自承担更适合的部分。

8.2 建议的进一步实验

为进一步验证方案有效性，可以采用消融实验：以基础 PPO 为基线，依次加入 CNN 地图编码、BFS 特征、目标缓存、门控融合和奖励塑形，并在地图 9、10 上分别比较平均总分、平均宝箱数、平均存活步数和终止率。同时可统计闪现成功脱险比例和局部磨蹭触发次数，从行为层面对策略改进进行解释。

9 关键代码分析

9.1 模型前向传播核心逻辑

模型前向传播先按固定维度切分 3601 维输入，再分别完成各分支编码。门控网络以英雄和地图嵌入为输入产生 5 类上下文权重，最终融合后同时输出动作 logits 与状态价值。核心逻辑如

下所示。

```
hero_emb = self.hero_encoder(hero_obs)
monster_emb = self.monster_encoder(monster_obs)
treasure_emb = self.treasure_encoder(treasure_obs)
buff_emb = self.buff_encoder(buff_obs)
topo_emb = self.topo_encoder(topo_obs)
memory_emb = self.memory_encoder(memory_obs)
map_emb = self.map_encoder(map_obs)

gate_logits = self.type_gate(torch.cat([hero_emb, map_emb], dim=1))
gate = torch.softmax(gate_logits, dim=1)
branches = torch.stack([monster_emb, treasure_emb, buff_emb, topo_emb, memory_emb], dim=1)
context = (gate.unsqueeze(-1) * branches).sum(dim=1)

fused = self.fusion(torch.cat([hero_emb, map_emb, context], dim=1))
logits = self.actor_head(fused)
value = self.critic_head(fused)
```

代码 9-1 多分支编码与门控融合核心实现

9.2 PPO 剪切损失核心逻辑

训练时首先在合法动作上计算新策略概率，然后提取实际动作在新旧策略中的概率比值，构造 PPO 剪切目标。价值损失同时启用 value clip，并加入策略熵。

```
new_prob = (one_hot * prob_dist).sum(1, keepdim=True).clamp(1e-9)
old_action_prob = (one_hot * old_prob).sum(1, keepdim=True).clamp(1e-9)
ratio = torch.exp(torch.log(new_prob) - torch.log(old_action_prob))

surr1 = ratio * advantage
surr2 = ratio.clamp(1 - self.clip_param, 1 + self.clip_param) * advantage
policy_loss = -torch.minimum(surr1, surr2).mean()

value_clip = old_value + (value_pred - old_value).clamp(-self.clip_param, self.clip_param)
value_loss = 0.5 * torch.maximum(
    (reward_sum - value_pred) ** 2,
    (reward_sum - value_clip) ** 2
).mean()

entropy_loss = (-prob_dist * torch.log(prob_dist.clamp(1e-9, 1.0))).sum(1).mean()
total_loss = self.vf_coef * value_loss + policy_loss - self.var_beta * entropy_loss
```

代码 9-2 PPO 剪切目标与价值损失实现

10 总结与展望

本课程设计围绕峡谷寻宝竞赛任务完成了一套基于 PPO 的深度强化学习智能体。最终方案以 3601 维复合状态为输入，通过多分支 MLP、CNN 地图编码和动态门控完成信息融合，并结合 BFS 局部路径、宝箱/BUFF 缓存、拓扑风险和近期行为记忆增强状态表达。在训练目标上，通过宝箱、生存、危险度、夹击、地形、BUFF、闪现和防磨蹭等多因素奖励塑形，引导策略在“主动寻宝”和“安全生存”之间取得平衡。训练流程进一步使用 1~8 号地图训练、9~10 号地图独立验证。

本项目的主要收获在于认识到复杂强化学习任务的性能往往不仅取决于算法名称，还取决于状态表示、奖励函数和训练工程细节。PPO 提供了稳定的策略优化框架，而 BFS 和显式记忆为神经网络补充了环境结构先验，使策略学习更有针对性。后续可在保留现有框架的基础上，引入循环神经网络或 Transformer 处理更长时间尺度的历史信息，采用课程学习逐步增加怪物压力，并通过系统化消融实验量化各个改进模块的贡献。

参考文献

[1] SUTTON R S, BARTO A G. Reinforcement Learning: An Introduction[M]. 2nd ed. MIT Press, 2018.

[2] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal Policy Optimization Algorithms[EB/OL]. arXiv:1707.06347, 2017.

[3] SCHULMAN J, MORITZ P, LEVINE S, et al. High-Dimensional Continuous Control Using Generalized Advantage Estimation[C]//ICLR, 2016.

[4] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518: 529-533.

[5] 项目最终训练代码包. gorge_chase-ppo-34055-2026_04_27_09_07_26-15.0.1.zip[Z]. 2026-04-27.

附录 A 最终工程文件说明

文件/目录	主要作用
agent_ppo/model/model.py	定义多分支编码、CNN 地图编码、动态门控和 Actor/Critic 网络
agent_ppo/algorithm/algorithm.py	实现 PPO 损失、合法动作掩码、mini-batch 多轮优化和训练指标监控
agent_ppo/feature/preprocessor.py	完成状态提取、BFS、目标记忆、拓扑特征、8 通道地图与奖励计算
agent_ppo/feature/definition.py	定义 ObsData、ActData、SampleData 以及 GAE 样本处理
agent_ppo/workflow/train_workflow.py	实现训练 episode、周期验证、模型保存和指标上报
agent_ppo/conf/conf.py	定义观测维度、模型维度、PPO 超参数和奖励系数
agent_ppo/conf/train_env_conf.toml	定义训练地图、宝箱、BUFF、怪物和最大步数等环境配置
ckpt/model.ckpt-34055.pkl	最终训练检查点

表 A-1 最终训练包主要文件

11 分工说明

每个组员独立完成一套方案后，各自独立测试，选出最好方案后分发组员继续迭代，工作量基本是每人各占 1/3。其余工作，报告由陈旭东完成，ppt 由南怡波完成，视频说明由刘润章完成。